Sprint 5: S05 T01: Tasca mètodes de mostreig

Nivel I,I,II

Sampling Summary: Nivels I,II i III - Cuadros resúmenes y Boxplot

Nivell 1

Exercici 1

Agafa un conjunt de dades de tema esportiu que t'agradi. Realitza un mostreig de les dades generant una mostra aleatòria simple i una mostra sistemàtica.

```
import random as rd
import numpy as np
import pandas as pd
import seaborn as sns
from matplotlib import pyplot as plt
from sklearn.model_selection import train_test_split
from imblearn.over_sampling import SMOTE

import warnings
warnings.filterwarnings('ignore')
```

A) Data Frame

Para realizar este Sprint he seleccionado la información contenida en la página web: https://www.kaggle.com/datasets/heesoo37/120-years-of-olympic-history-athletes-and-results

En esta web se encuentra disponible una base de datos histórica de los juegos olímpicos de verano e inviderno, desde Athens 1896 hasta Rio 2016

```
In [6]:
         df atletas= pd.read csv(r"C:\Users\hecto\OneDrive\Documentos\IT Data Science\Sprint5
         df_pais=pd.read_csv(r"C:\Users\hecto\OneDrive\Documentos\IT Data Science\Sprint5\arc
In [7]:
         df_atletas.info()
        <class 'pandas.core.frame.DataFrame'>
        RangeIndex: 271116 entries, 0 to 271115
        Data columns (total 15 columns):
             Column Non-Null Count
         0
             ID
                     271116 non-null
                                     int64
         1
             Name
                     271116 non-null object
         2
             Sex
                     271116 non-null object
                     261642 non-null float64
         3
         4
             Height 210945 non-null float64
             Weight 208241 non-null float64
         5
                     271116 non-null object
         6
             Team
                     271116 non-null object
         7
             NOC
                     271116 non-null object
         8
             Games
                     271116 non-null int64
         10 Season 271116 non-null object
```

11 City 271116 non-null object
12 Sport 271116 non-null object
13 Event 271116 non-null object
14 Medal 39783 non-null object
dtypes: float64(3), int64(2), object(10)
memory usage: 31.0+ MB

In [8]:

df_atletas.head(5)

Out[8]:		ID	Name	Sex	Age	Height	Weight	Team	NOC	Games	Year	Season	
	0	1	A Dijiang	М	24.0	180.0	80.0	China	CHN	1992 Summer	1992	Summer	Barce
	1	2	A Lamusi	М	23.0	170.0	60.0	China	CHN	2012 Summer	2012	Summer	Lo
	2	3	Gunnar Nielsen Aaby	М	24.0	NaN	NaN	Denmark	DEN	1920 Summer	1920	Summer	Antw€
	3	4	Edgar Lindenau Aabye	М	34.0	NaN	NaN	Denmark/Sweden	DEN	1900 Summer	1900	Summer	
	4	5	Christine Jacoba Aaftink	F	21.0	185.0	82.0	Netherlands	NED	1988 Winter	1988	Winter	Ca
	4												•

Detalle de los campos:

El archivo atleta_eventos.csv contiene 271116 filas y 15 columnas; Cada fila corresponde a un atleta individual compitiendo en un evento olímpico individual.

```
ID - Unique number for each athlete;
```

Name - Athlete's name;

Sex - M or F;

Age - Integer;

Height - In centimeters;

Weight - In kilograms;

Team - Team name;

NOC - National Olympic Committee 3-letter code;

Games - Year and season;

Year - Integer;

Season - Summer or Winter;

City - Host city;

Sport - Sport;

Event - Event;

Medal - Gold, Silver, Bronze, or NA.

df_atletas.describe()

Out[9]:

	ID	Age	Height	Weight	Year
count	271116.000000	261642.000000	210945.000000	208241.000000	271116.000000
mean	68248.954396	25.556898	175.338970	70.702393	1978.378480
std	39022.286345	6.393561	10.518462	14.348020	29.877632
min	1.000000	10.000000	127.000000	25.000000	1896.000000
25%	34643.000000	21.000000	168.000000	60.000000	1960.000000
50%	68205.000000	24.000000	175.000000	70.000000	1988.000000
75 %	102097.250000	28.000000	183.000000	79.000000	2002.000000
max	135571.000000	97.000000	226.000000	214.000000	2016.000000

Adicionalmente, existe otro Data Frame que contiene el país federado en el Comité Olímpico Internacional y la federaión a la que pertenecen.

Aunque es una información redundante, ya que la base da datos de atletas contiene la información del país por el que compiten los atletas, juntaremos los dos data frame para tener la información completa.

```
In [10]: df_pais.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 230 entries, 0 to 229
Data columns (total 3 columns):
# Column Non-Null Count Dtype
--- 0 NOC 230 non-null object
1 region 227 non-null object
2 notes 21 non-null object
dtypes: object(3)
```

memory usage: 5.5+ KB

In [11]: df

df_pais.head(5)

notes	region	NOC		Out[11]:
NaN	Afghanistan	AFG	0	
Netherlands Antilles	Curacao	АНО	1	
NaN	Albania	ALB	2	
NaN	Algeria	ALG	3	
NaN	Andorra	AND	4	

Descripción de los campos:

NOC : Código Federación region : País Federado notes: comentarios

B) Integración de los dos data frames

In [12]:

df_merged = pd.merge(df_atletas, df_pais, on='NOC', how='left')

In [13]:

df_merged.head()

Out[13]:		ID	Name	Sex	Age	Height	Weight	Team	NOC	Games	Year	Season	
	0	1	A Dijiang	М	24.0	180.0	80.0	China	CHN	1992 Summer	1992	Summer	Barce
	1	2	A Lamusi	М	23.0	170.0	60.0	China	CHN	2012 Summer	2012	Summer	Lo
	2	3	Gunnar Nielsen Aaby	М	24.0	NaN	NaN	Denmark	DEN	1920 Summer	1920	Summer	Antwe
	3	4	Edgar Lindenau Aabye	М	34.0	NaN	NaN	Denmark/Sweden	DEN	1900 Summer	1900	Summer	
	4	5	Christine Jacoba Aaftink	F	21.0	185.0	82.0	Netherlands	NED	1988 Winter	1988	Winter	Ca
	4												

C) Creación de una nueva variable BMI (indice de Masa Corpotal)

In [15]:

df_merged.head(5)

Out[15]:		ID	Name	Sex	Age	Height	Weight	Team	NOC	Games	Year	Season	
	0	1	A Dijiang	М	24.0	180.0	80.0	China	CHN	1992 Summer	1992	Summer	Barce
	1	2	A Lamusi	М	23.0	170.0	60.0	China	CHN	2012 Summer	2012	Summer	Lo
	2	3	Gunnar Nielsen Aaby	М	24.0	NaN	NaN	Denmark	DEN	1920 Summer	1920	Summer	Antwe
	3	4	Edgar Lindenau Aabye	М	34.0	NaN	NaN	Denmark/Sweden	DEN	1900 Summer	1900	Summer	
	4	5	Christine Jacoba Aaftink	F	21.0	185.0	82.0	Netherlands	NED	1988 Winter	1988	Winter	Ca

```
In [16]:
            df_merged.isnull().any()
                      False
           ID
Out[16]:
           Name
                      False
           Sex
                      False
                       True
           Age
          Height
                       True
          Weight
                       True
           Team
                      False
          NOC
                      False
                      False
           Games
           Year
                      False
                      False
           Season
                      False
           City
           Sport
                      False
           Event
                      False
          Medal
                       True
           region
                       True
           notes
                       True
           BMI
                       True
           dtype: bool
In [17]:
            df_Age_ok = df_merged[np.isfinite(df_merged['Age'])]
            df_Age_ok.head()
              ID
                                      Height Weight
                                                                         NOC
Out[17]:
                            Sex
                                 Age
                                                                  Team
                                                                                Games
                                                                                        Year
                                                                                               Season
                    Name
                                                                         CHN
                  A Dijiang
                                        180.0
                                                  0.08
                                                                                        1992
                                 24.0
                                                                  China
                                                                                              Summer
                                                                                                         Barce
                             Μ
                                                                               Summer
                                                                                  2012
                                                                         CHN
               2
                                 23.0
                                        170.0
                                                  60.0
                                                                                        2012
                  A Lamusi
                                                                  China
                                                                                              Summer
                                                                                                          Lo
                                                                               Summer
                    Gunnar
                                                                                  1920
                                                                         DEN
           2
               3
                   Nielsen
                                 24.0
                                                  NaN
                                                               Denmark
                                                                                        1920
                                         NaN
                                                                                              Summer Antwe
                             M
                                                                               Summer
                     Aaby
                     Edgar
                                                                                  1900
               4 Lindenau
                                                                                        1900
           3
                                 34.0
                                         NaN
                                                       Denmark/Sweden
                                                                         DEN
                                                                                             Summer
                                                                               Summer
                    Aabye
                  Christine
                                                                                  1988
               5
                    Jacoba
                              F 21.0
                                        185.0
                                                  82.0
                                                            Netherlands
                                                                         NED
                                                                                         1988
                                                                                                Winter
                                                                                                           Ca
                                                                                 Winter
                    Aaftink
In [18]:
            df_Age_ok.describe()
Out[18]:
                             ID
                                          Age
                                                       Height
                                                                      Weight
                                                                                       Year
                                                                                                       BMI
                                                210068.000000
                                                               207379.000000
                  261642.000000
                                 261642.000000
                                                                              261642.000000
                                                                                             206165.000000
           count
                   68291.263960
                                     25.556898
                                                   175.351367
                                                                   70.712603
                                                                                1980.100221
                                                                                                  22.784242
           mean
             std
                   38997.527135
                                      6.393561
                                                     10.524847
                                                                    14.358602
                                                                                  28.629035
                                                                                                   2.912173
             min
                        1.000000
                                      10.000000
                                                   127.000000
                                                                   25.000000
                                                                                1896.000000
                                                                                                   8.360954
```

	ID	Age	Height	Weight	Year	ВМІ
25%	34755.250000	21.000000	168.000000	60.000000	1964.000000	20.957171
50%	68198.000000	24.000000	175.000000	70.000000	1988.000000	22.530864
75%	102108.750000	28.000000	183.000000	79.000000	2004.000000	24.212293
max	135571.000000	97.000000	226.000000	214.000000	2016.000000	63.901580

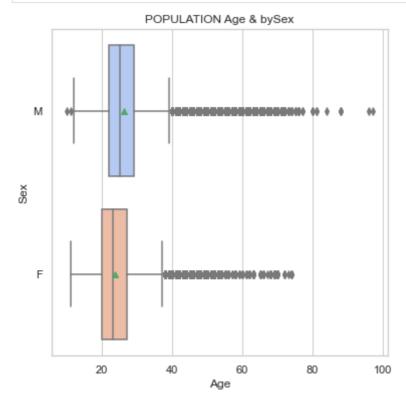
La media de edad de la base de datos sin valores nulos es de 25.557 años, y es la primera varible que vamos a usar para validar las muestras obtenidas.

Con el objeto de tener otra variable de control de las muestras propuestas, se ha definido la variable BMI que sintetiza en un índice, dos campos de información contenidos en el Data frame: Height y Weitht.

La media de BMI = 22.784, será otra de las variables de control para validar las muestras obtenidas.

- D) Representación gráfica de la información relevante
- d.1) Boxplot de distribución de las edades de los atletas por sexo (Age bySex)

```
plt.figure(figsize=(6,6))
    plt.title('POPULATION Age & bySex')
    plot1= sns.boxplot(data=df_Age_ok.sort_values(by="Age",ascending=True), x="Age", y="
    plot1.figure.savefig("Grafico1_age_sex_plot.png")
```



```
In [20]:
    real_mean =round( df_Age_ok.Age.sum()/len(df_Age_ok),3)
    print("Edad Media de la Población: ", real_mean)
```

Edad Media de la Población: 25.557

```
In [21]:
    real_bySex_mean= df_Age_ok.groupby(by="Sex").mean("Age")
    print("Edad Media de la Población bySex", round(real_bySex_mean["Age"],3))
```

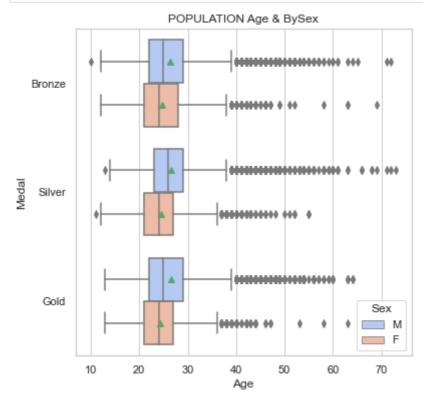
Edad Media de la Población bySex Sex

F 23.733 M 26.278

Name: Age, dtype: float64

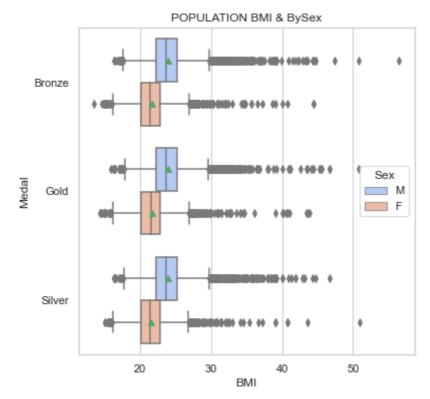
d.2) Boxplot de distribución de las edades de los atletas por Medallas y sexo (Age/ Medal bySex)

```
plt.figure(figsize=(6,6))
    plt.title(f'POPULATION Age & BySex')
    plot1= sns.boxplot(data=df_Age_ok.sort_values(by="Age",ascending=True), x="Age", y="
    plot1.figure.savefig("Grafico1_age_Sex_Medal_plot.png")
```



d.3) Boxplot de distribución del BMI de los atletas por Medallas y sexo (BMI / Medal bySex)

```
plt.figure(figsize=(6,6))
    plt.title(f'POPULATION BMI & BySex')
    plot1= sns.boxplot(data=df_Age_ok.sort_values(by="BMI",ascending=True), x="BMI", y="
    plot1.figure.savefig("Grafico1_BMI_Medal_Sex_plot.png")
```



E) Simple random sampling

In [24]: df_Age_ok.shape

Out[24]: (261642, 18)

In [25]:
 df=df_Age_ok
 simple_rand = df.sample(frac=0.1, replace=True, random_state=26164)

In [26]: simple_rand.head()

Out[26]:		ID	Name	Sex	Age	Height	Weight	Team	NOC	Games	Year	Seasor
	90047	45631	Lynley Joye Hannen (- Coventry)	F	24.0	175.0	70.0	New Zealand	NZL	1988 Summer	1988	Summe
	53951	27679	Hilaire Walter Deprez	М	30.0	NaN	NaN	Belgium	BEL	1952 Summer	1952	Summe
	80634	40939	Gerald Sydney Goddard	М	31.0	NaN	NaN	South Africa	RSA	1952 Summer	1952	Summe
	111309	56315	Josef Jungmann	М	36.0	NaN	NaN	Czechoslovakia	TCH	1924 Summer	1924	Summe

```
ID
                             Name Sex Age Height Weight
                                                                             NOC
                                                                                            Year
                                                                      Team
                                                                                    Games
                                                                                                  Seasor
                                                                                      1968
                               Ezio
                                                         68.0
                                                                                            1968
                                                                                                   Winte
            48750 25126
                                         23.0
                                                178.0
                                                                              ITA
                                     M
                                                                        Italy
                           Damolin
                                                                                    Winter
                                                                                                      •
In [27]:
           simple_rand.shape
          (26164, 18)
Out[27]:
In [28]:
           simple_rand_mean= simple_rand["Age"].mean()
           print("Edad Media Simple Random Sampling : ", round(simple_rand_mean,3))
          Edad Media Simple Random Sampling :
In [29]:
           simple rand bySex mean= simple rand.groupby(by="Sex").mean("Age")
           print("Edad Media Simple Random Sampling by", round(simple_rand_bySex_mean["Age"],3)
          Edad Media Simple Random Sampling by Sex
                23.852
          F
          Μ
                26.252
          Name: Age, dtype: float64
          F) Systematic sampling
In [30]:
           index = np.arange(0,len(df_Age_ok),step=10)
           systematic_sample = df.iloc[index]
           systematic_sample.head()
              ID
                                 Age Height Weight
                                                               NOC
                                                                                                 City
Out[30]:
                     Name Sex
                                                        Team
                                                                      Games
                                                                              Year
                                                                                    Season
                                                                        1992
                   A Dijiang
                                 24.0
                                        180.0
                                                 0.08
                                                               CHN
                                                                              1992
               1
                             Μ
                                                        China
                                                                                   Summer
                                                                                            Barcelona Ba
                                                                     Summer
                                                                        1992
                   Per Knut
                                                       United
          10
                                                                                     Winter Albertville
               6
                                                 75.0
                                                               USA
                                                                             1992
                             M 31.0
                                        188.0
                     Aaland
                                                        States
                                                                      Winter
                      John
                                                       United
                                                                        1992
          20
               7
                                 31.0
                                        183.0
                                                 72.0
                                                               USA
                                                                             1992
                                                                                     Winter Albertville
                    Aalberg
                                                        States
                                                                      Winter
                     Jorma
                                                                        1980
                                                                                                 Lake
          30 11
                      Ilmari
                             M 22.0
                                        182.0
                                                 76.5 Finland
                                                                FIN
                                                                              1980
                                                                                     Winter
                                                                      Winter
                                                                                               Placid
                      Aalto
```

) Name	Sex	Age	Height	Weight	Tean	n NOC	Games	Year	Season	City	
	40 16	Juhamatti 5 Tapio Aaltonen	М	28.0	184.0	85.0	Finland	d FIN	2014 Winter	2014	Winter	Sochi	
	4												
In [31]:	syst	ematic_samp	ole.	descri	be()								
out[31]:			ID		Age	Hei	ght	Weigh	it	Year		ВМІ	
	count	26165.000	000	26165.	000000	21060.000	000 20	0815.00000	0 26165	5.000000	20686.000	0000	
	mean	68290.991	630	25.	550468	175.427	825	70.87047	8 1980).239786	22.820)887	
	std	38999.405	751	6.	466348	10.542	359	14.45572	1 28	3.620467	2.926	5969	
	min	1.0000	000	11.	000000	135.000	000	25.00000	0 1896	5.000000	12.267	7562	
	25%	34755.0000	000	21.	000000	168.000	000	60.00000	0 1964	1.000000	20.983	3988	
	50%	68198.000	000	24.	000000	175.000	000	70.00000	0 1988	3.000000	22.587	7833	
	75%	102108.000	000	28.	000000	183.000	000	79.25000	0 2004	1.000000	24.22	1453	
	max	135571.0000	000	88.	000000	223.000	000	167.00000	0 2016	5.000000	50.975	5245	
n [32]:	-	ematic_mear t("Edad Med					_						
	Edad	Media Syste	emat	ic San	npling:	25.55							
n [33]:	<pre>systematic_bySex_mean= systematic_sample.groupby(by="Sex").mean("Age") print("Edad Media Systematic sampling by", round(systematic_bySex_mean["Age"],3))</pre>												
	F M	Media Syste 23.735 26.267 Age, dtype				by Sex							

Nivell 2

Exercici 2

Continua amb el conjunt de dades de tema esportiu i genera una mostra estratificada i una mostra utilitzant SMOTE (Synthetic Minority Oversampling Technique).

G) Stratified sampling

 Bronze
 M
 9243

 Silver
 M
 9092

 Bronze
 F
 3763

 Gold
 F
 3744

 Silver
 F
 3729

dtype: int64

In [35]: train, stratified_sample = train_test_split(df, test_size=0.1, stratify=df[['Medal',

In [36]: stratified_sample

Out[36]:		ID	Name	Sex	Age	Height	Weight	Team	NOC	Games	Year	Seasor
	73714	37454	Orlando E. Fuentes	М	21.0	NaN	65.0	United States	USA	1996 Summer	1996	Summe
	204610	102737	Albert "Al" Rossi	М	21.0	NaN	NaN	United States	USA	1952 Summer	1952	Summe
	119869	60686	Sergey Aleksandrovich Kirdyapkin	М	28.0	178.0	66.0	Russia	RUS	2008 Summer	2008	Summei
	204724	102802	Ernst Adriaan Rost-Onnes	М	30.0	184.0	76.0	Brazil	BRA	2016 Summer	2016	Summe
	238930	119783	Donald Alexander Thomas	М	24.0	191.0	81.0	Bahamas	ВАН	2008 Summer	2008	Summe
	•••	•••										
	111323	56324	Leovegildo Lins da Gama Jnior	М	22.0	173.0	69.0	Brazil	BRA	1976 Summer	1976	Summe
	118693	60051	Kim Jin-Hae	М	21.0	170.0	66.0	South Korea	KOR	1984 Winter	1984	Winte
	261175	130700	Yolanda Williams Garca	F	17.0	150.0	43.0	Cuba	CUB	1960 Summer	1960	Summe

F 22.0

M 23.0

Aleksey

Obmochayev

175.0

188.0

64.0

90.0

Canada CAN

Russia

RUS

26165 rows × 18 columns

23532 12373 Mlanie Blouin

87801 Aleksandrovich

174783

2012

2012

Summer

Summer

2012 Summer

2012 Summer

```
stratified_sample[['Medal', 'Sex']].value_counts()
In [37]:
         Medal
                   Sex
Out[37]:
         No Medal
                  Μ
                         15973
                   F
                          6287
         Gold
                           948
         Bronze
                           924
                  Μ
         Silver
                  Μ
                           909
         Bronze
                  F
                           376
         Gold
                   F
                           375
                   F
         Silver
                           373
         dtype: int64
In [38]:
         stratified_sample.info()
         <class 'pandas.core.frame.DataFrame'>
         Int64Index: 26165 entries, 73714 to 174783
         Data columns (total 18 columns):
              Column Non-Null Count Dtype
          #
                     -----
          0
              ID
                     26165 non-null int64
                     26165 non-null object
          1
              Name
                     26165 non-null object
          2
              Sex
                     26165 non-null float64
          3
              Age
          4
              Height 21022 non-null float64
          5
              Weight 20754 non-null float64
              Team
                     26165 non-null object
          6
          7
              NOC
                     26165 non-null object
          8
             Games
                     26165 non-null object
                     26165 non-null int64
          9
              Year
          10 Season 26165 non-null object
          11 City
                     26165 non-null object
          12 Sport 26165 non-null object
          13 Event 26165 non-null object
                     26165 non-null object
          14 Medal
             region 26127 non-null object
          16 notes
                                     object
                     488 non-null
          17 BMI
                      20626 non-null float64
         dtypes: float64(4), int64(2), object(12)
         memory usage: 3.8+ MB
```

Como se puede observar, la muestra estratificada se corresponde exáctamente con el 10% de los registros por tipos de medallas del Data frame original

```
In [39]: stratified_mean = round(stratified_sample.Age.mean(),3)
    print("Edad Media Stratified Sample: ", stratified_mean)

Edad Media Stratified Sample: 25.597

In [40]: stratified_bySex_mean= stratified_sample.groupby(by="Sex").mean("Age")
    print("Edad Media Stratified Sample by", round(stratified_bySex_mean["Age"],3))

Edad Media Stratified Sample by Sex
    F    23.749
    M    26.327
    Name: Age, dtype: float64
```

H) SMOTE (Synthetic Minority Oversampling Technique)

""" En muchas ocasiones, en un problema de clasificación ocurre que las clases que hay que discriminar no están representadas proporcionalmente, sino que una clase predomina sobre las otras o bien una clase tiene muy pocos elementos en el conjunto de datos.

Si se intenta construir un clasificador directamente sin tener en cuenta este desequilibrio, el clasificador resultante seguramente tenderá a predecir la clase mayoritaria, dado que esa acción minimiza el error cometido al acertar la mayoría de veces, y clasificará erróneamente de forma sistemática los elementos de la clase minoritaria, los cuales, en ocasiones, son seguramente los más interesantes.

Para solucionar este problema existen diferentes técnicas, como por ejemplo SMOTE, acrónimo de Synthetic Minority Oversampling Technique, basada en generar de forma sintética nuevos elementos de la clase minoritaria usando como referencia los elementos de dicha clase ya presentes en el conjunto de datos.

SMOTE es un algoritmo que a partir de un elemento de la clase minoritaria elegido al azar, escoge un cierto número de vecinos más cercanos y genera un nuevo elemento combinándolos linealmente de forma ponderada, e introduciendo un factor aleatorio para generar elementos parecidos. Existen diferentes versiones del algoritmo en función de cuántos vecinos y cómo se combinan para generar uno nuevo. Si repetimos este proceso es posible generar tantos elementos de la clase minoritaria como sea necesario para equilibrar el conjunto de datos. """

""" Las ventajas de SMOTE son:

- a) La información no se pierde
- b) Esta técnica es sencilla y se puede interpretar e implementar fácilmente en el modelo
- c) Mejora el overfitting como ejemplos sintéticos. Esto ayudará a generar nuevas instancias en lugar de replicarlas

```
.....
In [41]:
          df= df_Age_ok.dropna()
          df= df.loc[:,['Age','Sex','Medal','BMI']]
In [42]:
          df.info()
         <class 'pandas.core.frame.DataFrame'>
         Int64Index: 3477 entries, 734 to 270957
         Data columns (total 4 columns):
              Column Non-Null Count Dtype
          0
                     3477 non-null float64
              Age
                     3477 non-null object
          1
              Sex
             Medal 3477 non-null object
                                     float64
              BMI
                     3477 non-null
         dtypes: float64(2), object(2)
         memory usage: 135.8+ KB
In [43]:
          oversample = SMOTE(sampling_strategy='not majority', k_neighbors=2, random_state=257
```

X, y = oversample.fit_resample(df[['Age','BMI']], df[['Sex']])

Sex

Out[43]:

y.value_counts()

27582758

dtype: int64

```
In [44]: X['Sex'] = y
    stratified_SMOTE=(X.groupby('Sex').apply(lambda x: x.sample(n=138, random_state=2758)
In [45]: 
    stratified_SMOTE_mean= stratified_SMOTE.Age.mean()
    print("Edad Media Stratified_SMOTE : ", stratified_SMOTE_mean)

Edad Media Stratified_SMOTE : 24.37018125475649
```

La media de edad obtenida en este método es infeerior al la obtenida en el resto de métodos, porque el SMOTE no admite valores nulos en el Data Frame

la población se ha reducido al número de atletas que tenían medalas con valor no nulo, 2.758 y es sobre la cual se va a extraer la muestra

Por este motivo no se va a incluir los resultados en los cuadros resúmenes de todos los métodos.

```
In [46]:
          stratified_SMOTE_bySex_mean=stratified_SMOTE.groupby('Sex').Age.mean()
          print("Edad Media Stratified_SMOTE by",stratified_SMOTE_bySex_mean)
         Edad Media Stratified_SMOTE by Sex
              23.450507
              25.289855
         Μ
         Name: Age, dtype: float64
In [47]:
          stratified_SMOTE.info()
         <class 'pandas.core.frame.DataFrame'>
         Int64Index: 276 entries, 5117 to 2811
         Data columns (total 3 columns):
              Column Non-Null Count Dtype
                      -----
          0
                       276 non-null
                                       float64
              Age
          1
              BMI
                       276 non-null
                                       float64
                       276 non-null
                                       object
              Sex
         dtypes: float64(2), object(1)
         memory usage: 8.6+ KB
In [48]:
          stratified SMOTE.Sex.value counts(normalize=True)
              0.5
Out[48]:
              0.5
         Name: Sex, dtype: float64
In [49]:
          stratified SMOTE.head()
Out[49]:
                         BMI Sex
               Age
                                F
         5117
               19.0
                    20.077748
         4010
               25.0
                    19.227688
                                F
         3748
               26.0
                    20.446742
                                F
         4936
               19.0 19.918367
         4984 28.0 18.975448
                                F
```

Nivell 3

Exercici 3

I) Continua amb el conjunt de dades de tema esportiu i genera una mostra utilitzant el mètode Reservoir sampling.

```
In [50]:
          def reservoir_sampling(sample, population):
               reservoir = []
               for i in range(population):
                   if i < sample:</pre>
                       reservoir.append(i)
                   else:
                       j = rd.randint(0, i)
                       if j < sample:</pre>
                           reservoir[j] = i
               return reservoir
In [51]:
          sample = int(len(df_Age_ok)*0.1)+1
          population = len(df_Age_ok)
          reservoir_sample_index = reservoir_sampling(sample, population)
In [52]:
          population
          261642
Out[52]:
In [53]:
          sample
          26165
Out[53]:
In [54]:
          print(reservoir_sample_index[1:20])
          [86482, 2, 159041, 246840, 127105, 250874, 182115, 106176, 75206, 203561, 155815, 25
          1364, 13, 71632, 250277, 144147, 230521, 40619, 19]
In [55]:
          reservoir_sample = df_Age_ok.iloc[reservoir_sample_index]
In [56]:
          reservoir_mean = round(reservoir_sample.Age.mean(),3)
          print("Edad Media Reservoir Sample: ", reservoir_mean)
          Edad Media Reservoir Sample: 25.541
In [57]:
          reservoir_bySex_mean= reservoir_sample.groupby(by="Sex").mean("Age")
          print("Edad Media Reservoir Sample by", round(reservoir_bySex_mean["Age"],3))
          Edad Media Reservoir Sample by Sex
               23.730
               26.259
          Name: Age, dtype: float64
In [58]:
          reservoir_bySex_mean.shape
          (2, 6)
Out[58]:
In [59]:
```

```
reservoir_sample.to_csv('reservoir_sample.csv')

In [60]: print(reservoir_bySex_mean)

ID Age Height Weight Year BMI
Sex
F 71139.181390 23.730407 167.871289 60.252995 1992.819284 21.263684
M 67777.637921 26.259085 178.928332 75.662019 1975.279577 23.502014
```

Sampling Summary: Nivels I,II i III

1. Comparación Age mean:

```
In [61]: # Data Summary
# Create a dictionary with the mean outcomes
outcomes = {'sample_mean':[simple_rand_mean, systematic_mean,stratified_mean ,strati
# Transform dictionary into a data frame
outcomes = pd.DataFrame(outcomes, index=['Simple Random Sampling','Systematic Sampli
# Add a value corresponding to the absolute error
outcomes['%_error'] = (abs(outcomes['real_mean'] - outcomes['sample_mean']))/outcome
# Sort data frame by absolute error
outcomes.sort_values(by='real_mean')
```

Out[61]:

	sample_mean	real_mean	%_error
Simple Random Sampling	25.581371	25.557	0.095361
Systematic Sampling	25.550000	25.557	0.027390
Stratified Sampling	25.597000	25.557	0.156513
(*)Stratified SMOTE Sampling	24.370181	25.557	4.643811
Reservoir Sampling	25.541000	25.557	0.062605

La muestra que más se ajunta a la media de edad de la Población es la obtenida con Systematic Samplig.

(*) Los resultados obtenidos con el método Stratified SMOTE Sampling no son comparables con el resto de muestras, al haber tenido que reducir los registros que contenian valores "NaN".

2. Comparación Age bySex mean - Female:

```
In [62]: # Data Summary Mujeres
# Create a dictionary with the mean outcomes
outcomes = {'Female_sample_mean':[simple_rand_bySex_mean["Age"]["F"], systematic_byS
# Transform dictionary into a data frame
outcomes = pd.DataFrame(outcomes, index=['Simple Random Sampling','Systematic Sampli
# Add a value corresponding to the absolute error
outcomes['%_error'] = (abs(outcomes['Female_real_mean'] - outcomes['Female_sample_me
# Sort data frame by absolute error
outcomes.sort_values(by='Female_real_mean')
```

Out[62]:

	Female_sample_mean	Female_real_mean	%_error
Simple Random Sampling	23.852495	23.732881	0.504002
Systematic Sampling	23.735044	23.732881	0.009114
Stratified Sampling	23.749157	23.732881	0.068579
Reservoir Sampling	23.730407	23.732881	0.010425

Para el grupo de atletas femeninas el método que mejor ajusta la edad media es el Systematic Sampling y el segundo que mejor es Reservoir Sampling

3. Comparación Age bySex mean - Male:

```
In [63]: # Data Summary Male
# Create a dictionary with the mean outcomes
outcomes = {'Male_sample_mean':[simple_rand_bySex_mean["Age"]["M"], systematic_bySex

# Transform dictionary into a data frame
outcomes = pd.DataFrame(outcomes, index=['Simple Random Sampling','Systematic Sampli

# Add a value corresponding to the absolute error
outcomes['%_error'] = (abs(outcomes['Male_real_mean'] - outcomes['Male_sample_mean']

# Sort data frame by absolute error
outcomes.sort_values(by='Male_real_mean')
```

Out[63]:		Male_sample_mean	Male_real_mean	%_error
	Simple Random Sampling	26.252321	26.277562	0.096053
	Systematic Sampling	26.267058	26.277562	0.039973
	Stratified Sampling	26.327237	26.277562	0.189041
	Reservoir Sampling	26.259085	26.277562	0.070312

Para el grupo de aletas masculinos, el método que más aproxima la edad media es Stratified Sampling y el segundo mejor es Systematic Sampling

4. Comparación BMI - Female:

```
In [64]: # Data Summary Female
# Create a dictionary with the mean outcomes
outcomes = {'FemaleBMI_sample_mean':[simple_rand_bySex_mean["BMI"]["F"], systematic_
# Transform dictionary into a data frame
outcomes = pd.DataFrame(outcomes, index=['Simple Random Sampling','Systematic Sampli
# Add a value corresponding to the absolute error
outcomes['%_error'] = (abs(outcomes['FemaleBMI_real_mean'] - outcomes['FemaleBMI_sam
# Sort data frame by absolute error
outcomes.sort_values(by='FemaleBMI_real_mean')
```

Out[64]:		FemaleBMI_sample_mean	FemaleBMI_real_mean	%_error
	Simple Random Sampling	21.183741	21.193276	0.044990
	Systematic Sampling	21.232328	21.193276	0.184265

	FemaleBMI_sample_mean	FemaleBMI_real_mean	%_error
Stratified Sampling	21.172402	21.193276	0.098492
Reservoir Sampling	21.263684	21.193276	0.332217

En el caso del BMI la muestra que mejor representa la media de dicha variable en relación a la población de atletas femeninas es SImple Random Sampling

5. Comparación BMI - Male:

```
In [65]:
# Data Summary Male
# Create a dictionary with the mean outcomes
outcomes = {'MaleBMI_sample_mean':[simple_rand_bySex_mean["BMI"]["M"], systematic_by
# Transform dictionary into a data frame
outcomes = pd.DataFrame(outcomes, index=['Simple Random Sampling','Systematic Sampli
# Add a value corresponding to the absolute error
outcomes['%_error'] = (abs(outcomes['MaleBMI_real_mean'] - outcomes['MaleBMI_sample_
# Sort data frame by absolute error
outcomes.sort_values(by='MaleBMI_real_mean')
```

Out[65]:		MaleBMI_sample_mean	MaleBMI_real_mean	%_error
	Simple Random Sampling	23.545404	23.545317	0.000370
	Systematic Sampling	23.582727	23.545317	0.158883
	Stratified Sampling	23.557095	23.545317	0.050021
	Reservoir Sampling	23.502014	23.545317	0.183914

Se cumple también en el caso del BMI medio de la población de atletas masculinos donde la muestra que mejor se aproxima es SImple Random Sampling

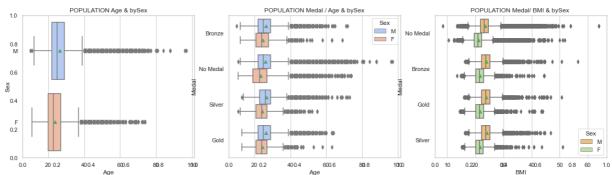
6. Resumén gráfico de Boxplot de las diferentes muestras y categorías de datos

6.1 Population Boxplot

```
In [66]:
    fig, axes = plt.subplots(1, 3, figsize=(20, 5), sharey=True)
    ax1 = fig.add_subplot(1, 3, 1)
    sns.set(style="whitegrid")
    plt.title('POPULATION Age & bySex')
    ax1 = sns.boxplot(data=df_Age_ok.sort_values(by="Age"), x="Age", y="Sex", orient="h",

    ax2 = fig.add_subplot(1, 3, 2)
    sns.set(style="whitegrid")
    plt.title('POPULATION Medal / Age & bySex')
    ax2 = sns.boxplot(data=df_Age_ok.sort_values(by="Age"), x="Age", y="Medal", hue="Sex"

    ax3 = fig.add_subplot(1, 3, 3)
    sns.set(style="whitegrid")
    plt.title('POPULATION Medal/ BMI & bySex ')
    ax3 = sns.boxplot(data=df_Age_ok.sort_values(by="BMI"), x="BMI", y="Medal",hue="Sex",
```



En relación a los datos de la Población, la edad media de las mujeres atletas es inferior a la de los hombres en todas las categorias: Age bySEx y Medal/Age bySex

En relación a Índice de masa corporal y tipos de medallas, las mujeres tienen una media de BMI inferior al de los hombres en todos los apartados

6.2 Simple Random Sample Boxplot



Esta muestra es la que mejor se ajusta a la media del BMI tanto en el colectivo de atletas femeninas como masculinos

6.3 Systematic Sample Boxplot

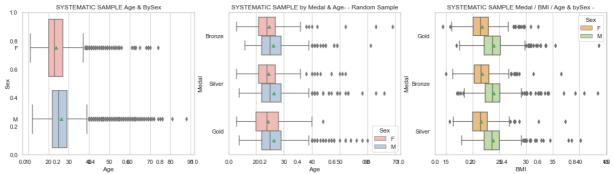
```
fig, axes = plt.subplots(1, 3, figsize=(20, 5), sharey=True)

ax1 = fig.add_subplot(1, 3, 1)
sns.set(style="whitegrid")
plt.title(f'SYSTEMATIC SAMPLE Age & BySex')
ax4= sns.boxplot(data=systematic_sample.sort_values(by="Age"), x="Age", y="Sex",orie

ax2 = fig.add_subplot(1, 3, 2)
sns.set(style="whitegrid")
plt.title(f'SYSTEMATIC SAMPLE Medal / Age & bySex')
```

```
ax5= sns.boxplot(data=systematic_sample.sort_values(by="Age"), x="Age", y="Medal", h
plt.title(f'SYSTEMATIC SAMPLE by Medal & Age- - Random Sample')

ax3 = fig.add_subplot(1, 3, 3)
sns.set(style="whitegrid")
plt.title(f'SYSTEMATIC SAMPLE Medal / BMI / Age & bySex -')
ax6= sns.boxplot(data=systematic_sample.sort_values(by="BMI"), x="BMI", y="Medal",or
```



La muestra obtenida con el método Systematic Sampling es la que mejor se ajusta a la edad media en las clasificaciones por Age bySex y Medal/Age bySex

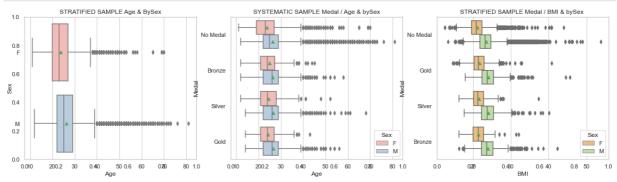
6.4 Stratified Sample Boxplot

```
In [69]:
    fig, axes = plt.subplots(1, 3, figsize=(20, 5), sharey=True)

ax1 = fig.add_subplot(1, 3, 1)
    sns.set(style="whitegrid")
    plt.title(f'STRATIFIED SAMPLE Age & BySex')
    ax4= sns.boxplot(data=stratified_sample.sort_values(by="Age"), x="Age", y="Sex",orie

ax2 = fig.add_subplot(1, 3, 2)
    sns.set(style="whitegrid")
    plt.title(f'STRATIFIED SAMPLE Medal / Age & bySex')
    ax5= sns.boxplot(data=stratified_sample.sort_values(by="Age"), x="Age", y="Medal", h
    plt.title(f'SYSTEMATIC SAMPLE Medal / Age & bySex')

ax3 = fig.add_subplot(1, 3, 3)
    sns.set(style="whitegrid")
    plt.title(f'STRATIFIED SAMPLE Medal / BMI & bySex ')
    ax6= sns.boxplot(data=stratified_sample.sort_values(by="BMI"), x="BMI", y="Medal", h
```

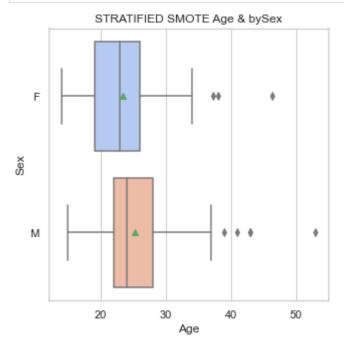


Las atletas con medalla, se corresponde con el colectivo minoritario y queda infrarepresentado en los métodos de muestreo generales.

Este método, por tanto, mejora las edades medias del colectivo de atletas femeninas clasificadas por tipos de medalla en relación a la edad media de la Población de Sex=femenino

6.5 Stratified SMOTE Boxplot

```
In [70]: plt.figure(figsize=(5,5))
    plt.title('STRATIFIED SMOTE Age & bySex')
    plot1= sns.boxplot(data=stratified_SMOTE.sort_values(by="Age",ascending=True), x="Ag
    plot1.figure.savefig("Grafico1_age_sex_plot.png")
```



(*) Los resultados obtenidos con el método Stratified SMOTE Sampling no son comparables con el resto de muestras, al haber tenido que reducir los registros que contenian valores "NaN"

6.6 Reservoir Sample Boxplot

```
In [71]:
           fig, axes = plt.subplots(1, 3, figsize=(20, 5), sharey=True)
           ax4 = fig.add_subplot(1, 3, 1)
           sns.set(style="whitegrid")
           plt.title(f'RESERVOIR SAMPLE ')
           ax4= sns.boxplot(data= reservoir_sample.sort_values(by="Age"), x="Age", y="Sex",orie
           ax5 = fig.add_subplot(1, 3, 2)
           sns.set(style="whitegrid")
           plt.title(f'RESERVOIR SAMPLE Medal / Age & BySex')
           ax5= sns.boxplot(data= reservoir sample.sort values(by="Age"), x="Age", y="Medal", or
           ax6 = fig.add_subplot(1, 3, 3)
           sns.set(style="whitegrid")
           plt.title(f'RESERVOIR SAMPLE Medal / BMI & bySex')
           ax6= sns.boxplot(data= reservoir sample.sort values(by="BMI"), x="BMI", y="Medal",or
                    RESERVOIR SAMPLE
                                                RESERVOIR SAMPLE Medal / Age & BySex
                                                                               RESERVOIR SAMPLE Medal / BMI & bySes
          0.8
F
```

Este método de muestreo es uno de los que mejor ajusta la edad média del colectivo de atletas femeninas clasificadas por tipos de medallas

80 1.0

0.20

200.2

80 1.0

0.4

0.2

0.010

200.2 30