Sprint 5: S05 T01: Tasca mètodes de mostreig

Nivel I,I,II

Sampling Summary: Nivels I,II i III - Cuadros resúmenes y Boxplot

Nivell 1

Exercici 1

Agafa un conjunt de dades de tema esportiu que t'agradi. Realitza un mostreig de les dades generant una mostra aleatòria simple i una mostra sistemàtica.

```
import random as rd
import numpy as np
import pandas as pd
import seaborn as sns
from matplotlib import pyplot as plt
from sklearn.model_selection import train_test_split
from imblearn.over_sampling import SMOTE

import warnings
warnings.filterwarnings('ignore')
```

A) Data Frame

Para realizar este Sprint he seleccionado la información contenida en la página web: https://www.kaggle.com/datasets/heesoo37/120-years-of-olympic-history-athletes-and-results

En esta web se encuentra disponible una base de datos histórica de los juegos olímpicos de verano e inviderno, desde Athens 1896 hasta Rio 2016

```
In [919...
          df atletas= pd.read csv(r"C:\Users\hecto\OneDrive\Documentos\IT Data Science\Sprint5
          df_pais=pd.read_csv(r"C:\Users\hecto\OneDrive\Documentos\IT Data Science\Sprint5\arc
In [920...
          df_atletas.info()
         <class 'pandas.core.frame.DataFrame'>
         RangeIndex: 271116 entries, 0 to 271115
         Data columns (total 15 columns):
              Column Non-Null Count
          0
              ID
                      271116 non-null
                                       int64
          1
              Name
                      271116 non-null object
          2
                      271116 non-null object
              Sex
          3
                      261642 non-null float64
          4
              Height 210945 non-null float64
              Weight 208241 non-null float64
          5
                      271116 non-null object
          6
              Team
          7
                      271116 non-null object
              NOC
          8
                      271116 non-null object
              Games
                      271116 non-null int64
             Season 271116 non-null object
```

11 City 271116 non-null object
12 Sport 271116 non-null object
13 Event 271116 non-null object
14 Medal 39783 non-null object
dtypes: float64(3), int64(2), object(10)

memory usage: 31.0+ MB

In [921...

df_atletas.head(5)

[921		ID	Name	Sex	Age	Height	Weight	Team	NOC	Games	Year	Season	
	0	1	A Dijiang	М	24.0	180.0	80.0	China	CHN	1992 Summer	1992	Summer	Barc€
	1	2	A Lamusi	М	23.0	170.0	60.0	China	CHN	2012 Summer	2012	Summer	Lo
	2	3	Gunnar Nielsen Aaby	М	24.0	NaN	NaN	Denmark	DEN	1920 Summer	1920	Summer	Antwe
	3	4	Edgar Lindenau Aabye	М	34.0	NaN	NaN	Denmark/Sweden	DEN	1900 Summer	1900	Summer	
	4	5	Christine Jacoba Aaftink	F	21.0	185.0	82.0	Netherlands	NED	1988 Winter	1988	Winter	Ca
	4												•

Detalle de los campos:

El archivo atleta_eventos.csv contiene 271116 filas y 15 columnas; Cada fila corresponde a un atleta individual compitiendo en un evento olímpico individual.

```
ID - Unique number for each athlete;
```

Name - Athlete's name;

Sex - M or F;

Age - Integer;

Height - In centimeters;

Weight - In kilograms;

Team - Team name;

NOC - National Olympic Committee 3-letter code;

Games - Year and season;

Year - Integer;

Season - Summer or Winter;

City - Host city;

Sport - Sport;

Event - Event;

Medal - Gold, Silver, Bronze, or NA.

df_atletas.describe()

Out[922...

	ID	Age	Height	Weight	Year
count	271116.000000	261642.000000	210945.000000	208241.000000	271116.000000
mean	68248.954396	25.556898	175.338970	70.702393	1978.378480
std	39022.286345	6.393561	10.518462	14.348020	29.877632
min	1.000000	10.000000	127.000000	25.000000	1896.000000
25%	34643.000000	21.000000	168.000000	60.000000	1960.000000
50%	68205.000000	24.000000	175.000000	70.000000	1988.000000
75%	102097.250000	28.000000	183.000000	79.000000	2002.000000
max	135571.000000	97.000000	226.000000	214.000000	2016.000000

Adicionalmente, existe otro Data Frame que contiene el país federado en el Comité Olímpico Internacional y la federaión a la que pertenecen.

Aunque es una información redundante, ya que la base da datos de atletas contiene la información del país por el que compiten los atletas, juntaremos los dos data frame para tener la información completa.

```
In [923... df_pais.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 230 entries, 0 to 229
Data columns (total 3 columns):
 # Column Non-Null Count Dtype
     NOC
 0
           230 non-null object
   region 227 non-null object notes 21 non-null object
dtypes: object(3)
memory usage: 5.5+ KB
```

In [924... df_pais.head(5)

Out[924...

	NOC	region	notes
0	AFG	Afghanistan	NaN
1	АНО	Curacao	Netherlands Antilles
2	ALB	Albania	NaN
3	ALG	Algeria	NaN
4	AND	Andorra	NaN

Descripción de los campos:

NOC: Código Federación region: País Federado notes: comentarios

B) Integración de los dos data frames

In [925...

df_merged = pd.merge(df_atletas, df_pais, on='NOC', how='left')

In [926...

df_merged.head()

Out[926		ID	Name	Sex	Age	Height	Weight	Team	NOC	Games	Year	Season	
	0	1	A Dijiang	М	24.0	180.0	80.0	China	CHN	1992 Summer	1992	Summer	Barce
	1	2	A Lamusi	М	23.0	170.0	60.0	China	CHN	2012 Summer	2012	Summer	Lo
	2	3	Gunnar Nielsen Aaby	М	24.0	NaN	NaN	Denmark	DEN	1920 Summer	1920	Summer	Antw€
	3	4	Edgar Lindenau Aabye	М	34.0	NaN	NaN	Denmark/Sweden	DEN	1900 Summer	1900	Summer	
	4	5	Christine Jacoba Aaftink	F	21.0	185.0	82.0	Netherlands	NED	1988 Winter	1988	Winter	Ca
	4												•

C) Creación de una nueva variable BMI (indice de Masa Corpotal)

In [927...
bmi = 10000 * df_merged["Weight"] / (df_merged["Height"] * df_merged["Height"])
df_merged["BMI"] = bmi

In [928...

df_merged.head(5)

		_	0	•									
Out[928		ID	Name	Sex	Age	Height	Weight	Team	NOC	Games	Year	Season	
	0	1	A Dijiang	М	24.0	180.0	80.0	China	CHN	1992 Summer	1992	Summer	Barce
	1	2	A Lamusi	М	23.0	170.0	60.0	China	CHN	2012 Summer	2012	Summer	Lo
	2	3	Gunnar Nielsen Aaby	М	24.0	NaN	NaN	Denmark	DEN	1920 Summer	1920	Summer	Antw€
	3	4	Edgar Lindenau Aabye	М	34.0	NaN	NaN	Denmark/Sweden	DEN	1900 Summer	1900	Summer	
	4	5	Christine Jacoba Aaftink	F	21.0	185.0	82.0	Netherlands	NED	1988 Winter	1988	Winter	Ca

```
In [929...
            df_merged.isnull().any()
                       False
           ID
Out[929...
           Name
                       False
           Sex
                       False
                       True
           Age
           Height
                       True
           Weight
                       True
           Team
                       False
           NOC
                       False
                       False
           Games
           Year
                       False
                       False
           Season
                       False
           City
           Sport
                       False
           Event
                       False
           Medal
                       True
           region
                       True
           notes
                       True
           BMI
                       True
           dtype: bool
In [930...
            df_Age_ok = df_merged[np.isfinite(df_merged['Age'])]
            df_Age_ok.head()
Out[930...
              ID
                                       Height Weight
                                                                         NOC
                            Sex
                                 Age
                                                                   Team
                                                                                 Games
                                                                                         Year
                                                                                                Season
                     Name
                                                                          CHN
                  A Dijiang
                                 24.0
                                         180.0
                                                   0.08
                                                                                         1992
                                                                   China
                                                                                               Summer
                                                                                                          Barce
                              Μ
                                                                                Summer
                                                                                   2012
                                                                          CHN
               2
                                 23.0
                                         170.0
                                                   60.0
                  A Lamusi
                                                                   China
                                                                                         2012
                                                                                               Summer
                                                                                                            Lo
                                                                                Summer
                    Gunnar
                                                                                   1920
                                                                          DEN
           2
               3
                    Nielsen
                                 24.0
                                                  NaN
                                                                Denmark
                                                                                         1920
                                         NaN
                                                                                               Summer Antwe
                              M
                                                                                Summer
                      Aaby
                     Edgar
                                                                                   1900
               4 Lindenau
                                                                                         1900
           3
                                 34.0
                                          NaN
                                                        Denmark/Sweden
                                                                          DEN
                                                                                              Summer
                                                                                Summer
                     Aabye
                   Christine
                                                                                   1988
               5
                    Jacoba
                                21.0
                                         185.0
                                                   82.0
                                                             Netherlands
                                                                          NED
                                                                                          1988
                                                                                                 Winter
                                                                                                            Ca
                                                                                  Winter
                    Aaftink
In [931...
            df_Age_ok.describe()
Out[931...
                             ID
                                           Age
                                                        Height
                                                                      Weight
                                                                                        Year
                                                                                                        BMI
                                                 210068.000000
                                                               207379.000000
                  261642.000000
                                 261642.000000
                                                                               261642.000000
                                                                                              206165.000000
           count
                    68291.263960
                                      25.556898
                                                    175.351367
                                                                    70.712603
                                                                                 1980.100221
                                                                                                   22.784242
           mean
              std
                    38997.527135
                                       6.393561
                                                     10.524847
                                                                    14.358602
                                                                                   28.629035
                                                                                                    2.912173
             min
                        1.000000
                                      10.000000
                                                    127.000000
                                                                    25.000000
                                                                                 1896.000000
                                                                                                    8.360954
```

	ID	Age	Height	Weight	Year	ВМІ
25%	34755.250000	21.000000	168.000000	60.000000	1964.000000	20.957171
50%	68198.000000	24.000000	175.000000	70.000000	1988.000000	22.530864
75%	102108.750000	28.000000	183.000000	79.000000	2004.000000	24.212293
max	135571.000000	97.000000	226.000000	214.000000	2016.000000	63.901580

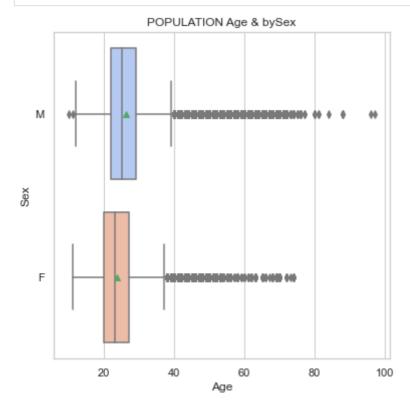
La media de edad de la base de datos sin valores nulos es de 25.557 años, y es la primera varible que vamos a usar para validar las muestras obtenidas.

Con el objeto de tener otra variable de control de las muestras propuestas, se ha definido la variable BMI que sintetiza en un índice, dos campos de información contenidos en el Data frame: Height y Weitht.

La media de BMI = 22.784, será otra de las variables de control para validar las muestras obtenidas.

- D) Representación gráfica de la información relevante
- d.1) Boxplot de distribución de las edades de los atletas por sexo (Age bySex)

```
plt.figure(figsize=(6,6))
plt.title('POPULATION Age & bySex')
plot1= sns.boxplot(data=df_Age_ok.sort_values(by="Age",ascending=True), x="Age", y="
plot1.figure.savefig("Grafico1_age_sex_plot.png")
```



```
real_mean =round( df_Age_ok.Age.sum()/len(df_Age_ok),3)
print("Edad Media de la Población: ", real_mean)
```

Edad Media de la Población: 25.557

```
real_bySex_mean= df_Age_ok.groupby(by="Sex").mean("Age")
print("Edad Media de la Población bySex", round(real_bySex_mean["Age"],3))
```

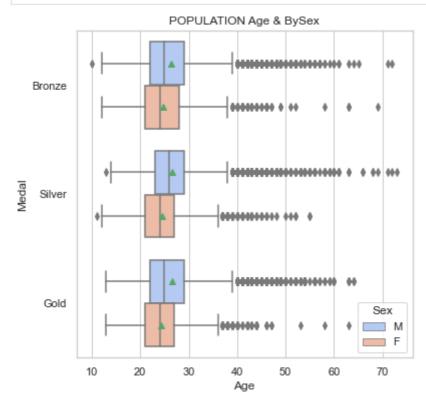
Edad Media de la Población bySex Sex

F 23.733 M 26.278

Name: Age, dtype: float64

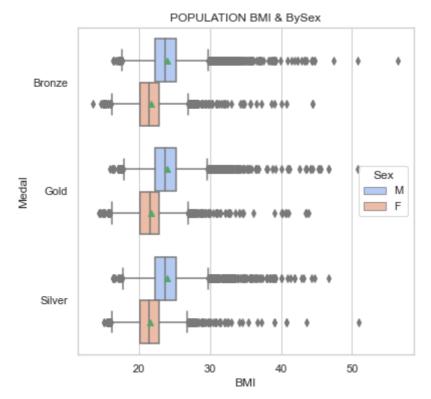
d.2) Boxplot de distribución de las edades de los atletas por Medallas y sexo (Age/ Medal bySex)

```
plt.figure(figsize=(6,6))
plt.title(f'POPULATION Age & BySex')
plot1= sns.boxplot(data=df_Age_ok.sort_values(by="Age",ascending=True), x="Age", y="
plot1.figure.savefig("Grafico1_age_Sex_Medal_plot.png")
```



d.3) Boxplot de distribución del BMI de los atletas por Medallas y sexo (BMI / Medal bySex)

```
plt.figure(figsize=(6,6))
  plt.title(f'POPULATION BMI & BySex')
  plot1= sns.boxplot(data=df_Age_ok.sort_values(by="BMI",ascending=True), x="BMI", y="
      plot1.figure.savefig("Grafico1_BMI_Medal_Sex_plot.png")
```



E) Simple random sampling

In [936... df_Age_ok.shape
Out[936... (261642, 18)

In [937...
 df=df_Age_ok
 simple_rand = df.sample(frac=0.1, replace=True, random_state=26164)

In [938... simple_rand.head()

Out[938		ID	Name	Sex	Age	Height	Weight	Team	NOC	Games	Year	Seasor
	90047	45631	Lynley Joye Hannen (- Coventry)	F	24.0	175.0	70.0	New Zealand	NZL	1988 Summer	1988	Summe
	53951	27679	Hilaire Walter Deprez	М	30.0	NaN	NaN	Belgium	BEL	1952 Summer	1952	Summe
	80634	40939	Gerald Sydney Goddard	М	31.0	NaN	NaN	South Africa	RSA	1952 Summer	1952	Summe
	111309	56315	Josef Jungmann	М	36.0	NaN	NaN	Czechoslovakia	TCH	1924 Summer	1924	Summe

```
ID
                             Name Sex Age Height Weight
                                                                             NOC
                                                                                             Year
                                                                       Team
                                                                                     Games
                                                                                                   Seasor
                                                                                       1968
                               Ezio
                                                          68.0
                                                                                             1968
                                                                                                    Winte
            48750 25126
                                         23.0
                                                 178.0
                                                                               ITA
                                      M
                                                                        Italy
                            Damolin
                                                                                     Winter
                                                                                                       •
In [939...
           simple_rand.shape
          (26164, 18)
Out[939...
In [866...
           simple_rand_mean= simple_rand["Age"].mean()
           print("Edad Media Simple Random Sampling : ", round(simple_rand_mean,3))
          Media de edades de la Simple Random Sampling :
In [940...
           simple rand bySex mean= simple rand.groupby(by="Sex").mean("Age")
           print("Edad Media Simple Random Sampling by", round(simple_rand_bySex_mean["Age"],3)
          Edad Media Simple Random Sampling by Sex
                23.852
          F
          Μ
                26.252
          Name: Age, dtype: float64
          F) Systematic sampling
In [807...
           index = np.arange(0,len(df_Age_ok),step=10)
           systematic_sample = df.iloc[index]
           systematic_sample.head()
Out[807...
              ID
                                 Age Height Weight
                                                               NOC
                                                                                                  City
                     Name Sex
                                                         Team
                                                                      Games
                                                                              Year
                                                                                     Season
                                                                        1992
                   A Dijiang
                                 24.0
                                        180.0
                                                  0.08
                                                               CHN
                                                                              1992
               1
                              Μ
                                                         China
                                                                                    Summer
                                                                                             Barcelona Ba
                                                                     Summer
                                                                        1992
                    Per Knut
                                                        United
          10
                                                                                     Winter Albertville
               6
                                                  75.0
                                                                USA
                                                                              1992
                              М
                                31.0
                                        188.0
                     Aaland
                                                        States
                                                                       Winter
                       John
                                                        United
                                                                        1992
          20
               7
                                 31.0
                                        183.0
                                                  72.0
                                                                USA
                                                                              1992
                                                                                     Winter Albertville
                    Aalberg
                                                        States
                                                                       Winter
                     Jorma
                                                                        1980
                                                                                                 Lake
          30 11
                      Ilmari
                              M 22.0
                                        182.0
                                                  76.5 Finland
                                                                FIN
                                                                              1980
                                                                                      Winter
                                                                       Winter
                                                                                                Placid
                      Aalto
```

	ID	Name S	Sex A	ge Heigh	t Weight	Team	NOC	Games	Year	Season	City
	40 16	Juhamatti Tapio Aaltonen	M 28	3.0 184.0) 85.0	Finland	FIN	2014 Winter	2014	Winter	Sochi
	4										•
In [808	syste	ematic_sampl	e.des	cribe()							
Out[808		I	D	Age	Hei	ght	Weigh	nt	Year	В	МІ
	count	26165.00000	0 261	65.000000	21060.000	000 20	815.00000	0 26165	5.000000	20686.0000	000
	mean	68290.99163	0	25.550468	175.427	825	70.87047	8 1980	0.239786	22.8208	387
	std	38999.40575	1	6.466348	10.542	359	14.45572	1 28	3.620467	2.9269	969
	min	1.00000	0	11.000000	135.000	000	25.00000	0 1896	5.000000	12.2675	562
	25%	34755.00000	0	21.000000	168.000	000	60.00000	0 1964	4.000000	20.9839	988
	50%	68198.00000	0	24.000000	175.000	000	70.00000	0 1988	3.000000	22.5878	333
	75%	102108.00000	0	28.000000	183.000	000	79.25000	0 2004	1.000000	24.2214	153
	max	135571.00000	0	88.000000	223.000	000	167.00000	0 2016	5.000000	50.9752	245
In [942	-	ematic_mean :("Edad Medi				_					
	Edad M	Media System	natic S	Sampling:	25.55						
In [943		ematic_bySex :("Edad Medi									"],3))
	F 2	Media System 23.735 26.267 Age, dtype:		, -	by Sex						

Nivell 2

Exercici 2

Continua amb el conjunt de dades de tema esportiu i genera una mostra estratificada i una mostra utilitzant SMOTE (Synthetic Minority Oversampling Technique).

G) Stratified sampling

 Bronze
 M
 9243

 Silver
 M
 9092

 Bronze
 F
 3763

 Gold
 F
 3744

 Silver
 F
 3729

dtype: int64

In [945... train, stratified_sample = train_test_split(df, test_size=0.1, stratify=df[['Medal',

In [946... stratified_sample

Out[946...

3Clacilied_Sample

**	ID	Name	Sex	Age	Height	Weight	Team	NOC	Games	Year	Season
1829	1012	Rubn Adorno Melndez	М	23.0	190.0	91.0	Puerto Rico	PUR	1964 Summer	1964	Summer
231605	116195	Kyoji Suga	М	28.0	173.0	61.0	Japan	JPN	1998 Winter	1998	Winter
239227	119922	Jennifer Elisabeth "Jenny" Thompson (-Cumpelik)	F	19.0	177.0	69.0	United States	USA	1992 Summer	1992	Summer
237101	118900	James "Jack" Taylor	М	24.0	NaN	NaN	Great Britain	GBR	1956 Summer	1956	Summer
46593	24046	Julia Mara Cruz Palacios	F	23.0	166.0	49.0	Spain	ESP	1992 Summer	1992	Summer
•••		•••								•••	
73191	37203	Johan Mohr Friele	М	53.0	NaN	NaN	Heira II	NOR	1920 Summer	1920	Summer
135228	68032	Lee Jun-Ho	М	28.0	171.0	65.0	South Korea	KOR	1994 Winter	1994	Winter
219373	110198	loannis Sidiropoulos	М	32.0	160.0	60.0	Greece	GRE	1988 Summer	1988	Summer
123885	62581	Georgios Kontogouris	М	24.0	190.0	100.0	Greece	GRE	2004 Summer	2004	Summer
171205	86042	Sofus Erhard Nielsen	М	24.0	NaN	NaN	Denmark	DEN	1912 Summer	1912	Summer

26165 rows × 18 columns

In [947... stratified_sample[['Medal', 'Sex']].value_counts()

```
Medal
                  Sex
Out[947...
         No Medal M
                         15973
                  F
                          6287
         Gold
                  Μ
                           948
         Bronze
                  Μ
                           924
         Silver
                  Μ
                           909
         Bronze
                  F
                           376
                  F
         Gold
                           375
         Silver
                  F
                           373
         dtype: int64
In [948...
         stratified_sample.info()
         <class 'pandas.core.frame.DataFrame'>
         Int64Index: 26165 entries, 1829 to 171205
         Data columns (total 18 columns):
             Column Non-Null Count Dtype
              -----
          a
             TD
                     26165 non-null int64
          1
             Name
                     26165 non-null object
                     26165 non-null object
          2
             Sex
                     26165 non-null float64
          3
             Age
          4
             Height 20945 non-null float64
          5
             Weight 20662 non-null float64
                     26165 non-null object
          6
             Team
          7
                     26165 non-null object
             NOC
          8
             Games 26165 non-null object
          9
                     26165 non-null int64
             Year
          10 Season 26165 non-null object
             City
                     26165 non-null object
          12 Sport 26165 non-null object
          13 Event
                     26165 non-null object
          14 Medal
                     26165 non-null object
          15 region 26137 non-null object
          16 notes
                     458 non-null
                                     object
          17 BMI
                     20533 non-null float64
         dtypes: float64(4), int64(2), object(12)
         memory usage: 3.8+ MB
```

Como se puede observar, la muestra estratificada se corresponde exáctamente con el 10% de los registros por tipos de medallas del Data frame original

H) SMOTE (Synthetic Minority Oversampling Technique)

""" En muchas ocasiones, en un problema de clasificación ocurre que las clases que hay que discriminar no están representadas proporcionalmente, sino que una clase predomina sobre las otras o bien una clase tiene muy pocos elementos en el conjunto de datos.

Si se intenta construir un clasificador directamente sin tener en cuenta este desequilibrio, el clasificador resultante seguramente tenderá a predecir la clase mayoritaria, dado que esa acción minimiza el error cometido al acertar la mayoría de veces, y clasificará erróneamente de forma sistemática los elementos de la clase minoritaria, los cuales, en ocasiones, son seguramente los más interesantes.

Para solucionar este problema existen diferentes técnicas, como por ejemplo SMOTE, acrónimo de Synthetic Minority Oversampling Technique, basada en generar de forma sintética nuevos elementos de la clase minoritaria usando como referencia los elementos de dicha clase ya presentes en el conjunto de datos.

SMOTE es un algoritmo que a partir de un elemento de la clase minoritaria elegido al azar, escoge un cierto número de vecinos más cercanos y genera un nuevo elemento combinándolos linealmente de forma ponderada, e introduciendo un factor aleatorio para generar elementos parecidos. Existen diferentes versiones del algoritmo en función de cuántos vecinos y cómo se combinan para generar uno nuevo. Si repetimos este proceso es posible generar tantos elementos de la clase minoritaria como sea necesario para equilibrar el conjunto de datos. """

""" Las ventajas de SMOTE son:

a) La información no se pierde

.....

- b) Esta técnica es sencilla y se puede interpretar e implementar fácilmente en el modelo
- c) Mejora el overfitting como ejemplos sintéticos. Esto ayudará a generar nuevas instancias en lugar de replicarlas

```
In [ ]:
          df= df_Age_ok.dropna()
          df= df.loc[:,['Age','Sex','Medal','BMI']]
In [952...
         df.info()
         <class 'pandas.core.frame.DataFrame'>
         Int64Index: 3477 entries, 734 to 270957
         Data columns (total 4 columns):
              Column Non-Null Count Dtype
          0
                     3477 non-null float64
              Age
                      3477 non-null object
          1
              Sex
              Medal 3477 non-null object
                                     float64
              BMI
                      3477 non-null
         dtypes: float64(2), object(2)
         memory usage: 135.8+ KB
In [953...
          oversample = SMOTE(sampling_strategy='not majority', k_neighbors=2, random_state=257
          X, y = oversample.fit_resample(df[['Age','BMI']], df[['Sex']])
          y.value_counts()
         Sex
Out[953...
                2758
                2758
         dtype: int64
```

```
In [954... X['Sex'] = y
    stratified_SMOTE=(X.groupby('Sex').apply(lambda x: x.sample(n=138, random_state=2758)
In [955... stratified_SMOTE_mean= stratified_SMOTE.Age.mean()
    print("Edad Media Stratified_SMOTE : ", stratified_SMOTE_mean)
```

Edad Media Stratified_SMOTE : 24.37018125475649

La media de edad obtenida en este método es infeerior al la obtenida en el resto de métodos, porque el SMOTE no admite valores nulos en el Data Frame

la población se ha reducido al número de atletas que tenían medalas con valor no nulo, 2.758 y es sobre la cual se va a extraer la muestra

Por este motivo no se va a incluir los resultados en los cuadros resúmenes de todos los métodos.

```
In [956...
          stratified_SMOTE_bySex_mean=stratified_SMOTE.groupby('Sex').Age.mean()
          print("Edad Media Stratified_SMOTE by",stratified_SMOTE_bySex_mean)
          Edad Media Stratified_SMOTE by Sex
               23.450507
               25.289855
         Μ
         Name: Age, dtype: float64
In [957...
          stratified_SMOTE.info()
          <class 'pandas.core.frame.DataFrame'>
          Int64Index: 276 entries, 5117 to 2811
         Data columns (total 3 columns):
               Column Non-Null Count Dtype
                      -----
          0
                       276 non-null
                                        float64
               Age
           1
               BMI
                       276 non-null
                                        float64
                       276 non-null
                                        object
               Sex
          dtypes: float64(2), object(1)
         memory usage: 8.6+ KB
In [958...
          stratified SMOTE.Sex.value counts(normalize=True)
               0.5
Out[958...
               0.5
         Name: Sex, dtype: float64
In [959...
          stratified SMOTE.head()
Out[959...
                         BMI Sex
                Age
                                 F
          5117
               19.0
                     20.077748
          4010
                25.0
                    19.227688
                                 F
          3748
                26.0
                    20.446742
                                 F
          4936
               19.0 19.918367
          4984 28.0 18.975448
                                 F
```

Nivell 3

Exercici 3

I) Continua amb el conjunt de dades de tema esportiu i genera una mostra utilitzant el mètode Reservoir sampling.

```
In [960...
           def reservoir_sampling(sample, population):
               reservoir = []
               for i in range(population):
                   if i < sample:</pre>
                        reservoir.append(i)
                   else:
                        j = rd.randint(0, i)
                       if j < sample:</pre>
                            reservoir[j] = i
               return reservoir
In [961...
           sample = int(len(df_Age_ok)*0.1)+1
           population = len(df_Age_ok)
           reservoir_sample_index = reservoir_sampling(sample, population)
In [962...
           population
          261642
Out[962...
In [963...
           sample
          26165
Out[963...
In [964...
           print(reservoir_sample_index[1:20])
          [84149, 80076, 240423, 232380, 5, 160695, 137827, 59785, 192278, 73416, 181517, 2502
          64, 234365, 199091, 260781, 45647, 149740, 180640, 62917]
In [965...
           reservoir_sample = df_Age_ok.iloc[reservoir_sample_index]
In [966...
           reservoir_mean = round(reservoir_sample.Age.mean(),3)
           print("Edad Media Reservoir Sample: ", reservoir_mean)
          Edad Media Reservoir Sample: 25.515
In [967...
           reservoir_bySex_mean= reservoir_sample.groupby(by="Sex").mean("Age")
           print("Edad Media Reservoir Sample by", round(reservoir_bySex_mean["Age"],3))
          Edad Media Reservoir Sample by Sex
               23.595
               26.274
          Name: Age, dtype: float64
In [968...
           reservoir_bySex_mean.shape
          (2, 6)
Out[968...
In [969...
```

```
reservoir_sample.to_csv('reservoir_sample.csv')

In [970... print(reservoir_bySex_mean)

ID Age Height Weight Year BMI
Sex
F 69447.596032 23.594817 167.757981 59.859728 1992.708598 21.163165
M 67839.692952 26.273512 178.889400 75.863956 1975.384517 23.561277
```

Sampling Summary: Nivels I,II i III

1. Comparación Age mean:

```
# Data Summary
# Create a dictionary with the mean outcomes
outcomes = {'sample_mean':[simple_rand_mean, systematic_mean,stratified_mean ,strati

# Transform dictionary into a data frame
outcomes = pd.DataFrame(outcomes, index=['Simple Random Sampling','Systematic Sampli

# Add a value corresponding to the absolute error
outcomes['%_error'] = (abs(outcomes['real_mean'] - outcomes['sample_mean']))/outcome

# Sort data frame by absolute error
outcomes.sort_values(by='real_mean')
```

Out[971...

	sample_mean	real_mean	%_error
Simple Random Sampling	25.581371	25.557	0.095361
Systematic Sampling	25.550000	25.557	0.027390
Stratified Sampling	25.585000	25.557	0.109559
(*)Stratified SMOTE Sampling	24.370181	25.557	4.643811
Reservoir Sampling	25.515000	25.557	0.164339

La muestra que más se ajunta a la media de edad de la Población es la obtenida con Systematic Samplig.

(*) Los resultados obtenidos con el método Stratified SMOTE Sampling no son comparables con el resto de muestras, al haber tenido que reducir los registros que contenian valores "NaN".

2. Comparación Age bySex mean - Female:

```
# Data Summary Mujeres
# Create a dictionary with the mean outcomes
outcomes = {'Female_sample_mean':[simple_rand_bySex_mean["Age"]["F"], systematic_byS

# Transform dictionary into a data frame
outcomes = pd.DataFrame(outcomes, index=['Simple Random Sampling','Systematic Sampli

# Add a value corresponding to the absolute error
outcomes['%_error'] = (abs(outcomes['Female_real_mean'] - outcomes['Female_sample_me

# Sort data frame by absolute error
outcomes.sort_values(by='Female_real_mean')
```

Out[972...

	Female_sample_mean	Female_real_mean	%_error
Simple Random Sampli	ng 23.852495	23.732881	0.504002
Systematic Sampli	ng 23.735044	23.732881	0.009114
Stratified Sampli	ng 23.700850	23.732881	0.134963
Reservoir Sampli	ng 23.594817	23.732881	0.581740

Para el grupo de atletas femeninas el método que mejor ajusta la edad media es el Systematic Sampling y el segundo que mejor es Reservoir Sampling

3. Comparación Age bySex mean - Male:

```
# Data Summary Male
# Create a dictionary with the mean outcomes
outcomes = {'Male_sample_mean':[simple_rand_bySex_mean["Age"]["M"], systematic_bySex
# Transform dictionary into a data frame
outcomes = pd.DataFrame(outcomes, index=['Simple Random Sampling','Systematic Sampli
# Add a value corresponding to the absolute error
outcomes['%_error'] = (abs(outcomes['Male_real_mean'] - outcomes['Male_sample_mean']
# Sort data frame by absolute error
outcomes.sort_values(by='Male_real_mean')

Out[973...

Male_sample_mean Male_real_mean %_error
```

Out[973		Male_sample_mean	Male_real_mean	%_error
	Simple Random Sampling	26.252321	26.277562	0.096053
	Systematic Sampling	26.267058	26.277562	0.039973
	Stratified Sampling	26.329583	26.277562	0.197969
	Reservoir Sampling	26.273512	26.277562	0.015409

Para el grupo de aletas masculinos, el método que más aproxima la edad media es Stratified Sampling y el segundo mejor es Systematic Sampling

4. Comparación BMI - Female:

```
# Data Summary Female
# Create a dictionary with the mean outcomes
outcomes = {'FemaleBMI_sample_mean':[simple_rand_bySex_mean["BMI"]["F"], systematic_

# Transform dictionary into a data frame
outcomes = pd.DataFrame(outcomes, index=['Simple Random Sampling','Systematic Sampli

# Add a value corresponding to the absolute error
outcomes['%_error'] = (abs(outcomes['FemaleBMI_real_mean'] - outcomes['FemaleBMI_sam'

# Sort data frame by absolute error
outcomes.sort_values(by='FemaleBMI_real_mean')
```

Out[974		FemaleBMI_sample_mean	FemaleBMI_real_mean	%_error
	Simple Random Sampling	21.183741	21.193276	0.044990
	Systematic Sampling	21.232328	21.193276	0.184265

	FemaleBMI_sample_mean	FemaleBMI_real_mean	%_error
Stratified Sampling	21.152128	21.193276	0.194154
Reservoir Sampling	21.163165	21.193276	0.142079

En el caso del BMI la muestra que mejor representa la media de dicha variable en relación a la población de atletas femeninas es SImple Random Sampling

5. Comparación BMI - Male:

```
# Data Summary Male
# Create a dictionary with the mean outcomes
outcomes = {'MaleBMI_sample_mean':[simple_rand_bySex_mean["BMI"]["M"], systematic_by

# Transform dictionary into a data frame
outcomes = pd.DataFrame(outcomes, index=['Simple Random Sampling','Systematic Sampli

# Add a value corresponding to the absolute error
outcomes['%_error'] = (abs(outcomes['MaleBMI_real_mean'] - outcomes['MaleBMI_sample_

# Sort data frame by absolute error
outcomes.sort_values(by='MaleBMI_real_mean')
```

Out[975...

	MaleBMI_sample_mean	MaleBMI_real_mean	%_error
Simple Random Sampling	23.545404	23.545317	0.000370
Systematic Sampling	23.582727	23.545317	0.158883
Stratified Sampling	23.542989	23.545317	0.009889
Reservoir Sampling	23.561277	23.545317	0.067781

Se cumple también en el caso del BMI medio de la población de atletas masculinos donde la muestra que mejor se aproxima es SImple Random Sampling

6. Resumén gráfico de Boxplot de las diferentes muestras y categorías de datos

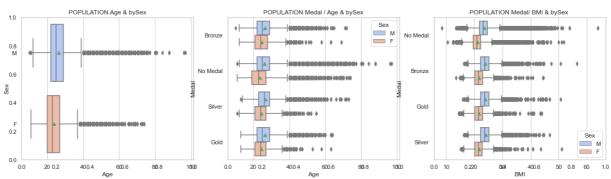
6.1 Population Boxplot

```
fig, axes = plt.subplots(1, 3, figsize=(20, 5), sharey=True)

ax1 = fig.add_subplot(1, 3, 1)
sns.set(style="whitegrid")
plt.title('POPULATION Age & bySex')
ax1= sns.boxplot(data=df_Age_ok.sort_values(by="Age"), x="Age", y="Sex", orient="h",

ax2 = fig.add_subplot(1, 3, 2)
sns.set(style="whitegrid")
plt.title('POPULATION Medal / Age & bySex')
ax2= sns.boxplot(data=df_Age_ok.sort_values(by="Age"), x="Age", y="Medal", hue="Sex"

ax3 = fig.add_subplot(1, 3, 3)
sns.set(style="whitegrid")
plt.title('POPULATION Medal/ BMI & bySex ')
ax3= sns.boxplot(data=df_Age_ok.sort_values(by="BMI"), x="BMI", y="Medal",hue="Sex",
```



En relación a los datos de la Población, la edad media de las mujeres atletas es inferior a la de los hombres en todas las categorias: Age bySEx y Medal/Age bySex

En relación a Índice de masa corporal y tipos de medallas, las mujeres tienen una media de BMI inferior al de los hombres en todos los apartados

6.2 Simple Random Sample Boxplot



Esta muestra es la que mejor se ajusta a la media del BMI tanto en el colectivo de atletas femeninas como masculinos

6.3 Systematic Sample Boxplot

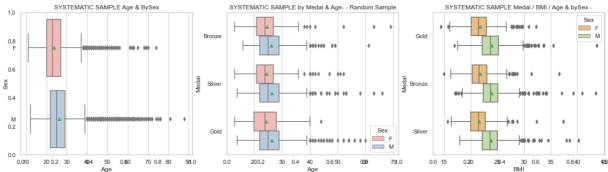
```
fig, axes = plt.subplots(1, 3, figsize=(20, 5), sharey=True)

ax1 = fig.add_subplot(1, 3, 1)
sns.set(style="whitegrid")
plt.title(f'SYSTEMATIC SAMPLE Age & BySex')
ax4= sns.boxplot(data=systematic_sample.sort_values(by="Age"), x="Age", y="Sex",orie

ax2 = fig.add_subplot(1, 3, 2)
sns.set(style="whitegrid")
plt.title(f'SYSTEMATIC SAMPLE Medal / Age & bySex')
```

```
ax5= sns.boxplot(data=systematic_sample.sort_values(by="Age"), x="Age", y="Medal", h
plt.title(f'SYSTEMATIC SAMPLE by Medal & Age- - Random Sample')

ax3 = fig.add_subplot(1, 3, 3)
sns.set(style="whitegrid")
plt.title(f'SYSTEMATIC SAMPLE Medal / BMI / Age & bySex -')
ax6= sns.boxplot(data=systematic_sample.sort_values(by="BMI"), x="BMI", y="Medal",or
```



La muestra obtenida con el método Systematic Sampling es la que mejor se ajusta a la edad media en las clasificaciones por Age bySex y Medal/Age bySex

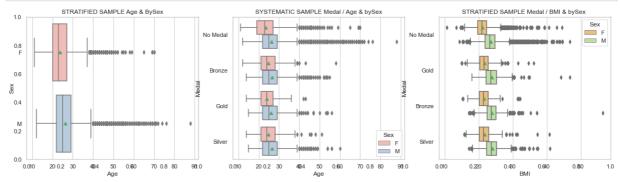
6.4 Stratified Sample Boxplot

```
fig, axes = plt.subplots(1, 3, figsize=(20, 5), sharey=True)

ax1 = fig.add_subplot(1, 3, 1)
sns.set(style="whitegrid")
plt.title(f'STRATIFIED SAMPLE Age & BySex')
ax4= sns.boxplot(data=stratified_sample.sort_values(by="Age"), x="Age", y="Sex",orie

ax2 = fig.add_subplot(1, 3, 2)
sns.set(style="whitegrid")
plt.title(f'STRATIFIED SAMPLE Medal / Age & bySex')
ax5= sns.boxplot(data=stratified_sample.sort_values(by="Age"), x="Age", y="Medal", h
plt.title(f'SYSTEMATIC SAMPLE Medal / Age & bySex')

ax3 = fig.add_subplot(1, 3, 3)
sns.set(style="whitegrid")
plt.title(f'STRATIFIED SAMPLE Medal / BMI & bySex ')
ax6= sns.boxplot(data=stratified_sample.sort_values(by="BMI"), x="BMI", y="Medal", h
```



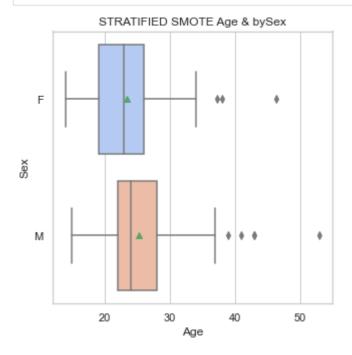
Las atletas con medalla, se corresponde con el colectivo minoritario y queda infrarepresentado en los métodos de muestreo generales.

Este método, por tanto, mejora las edades medias del colectivo de atletas femeninas clasificadas por tipos de medalla en relación a la edad media de la Población de Sexefemenino

6.5 Stratified SMOTE Boxplot

```
In [980...
```

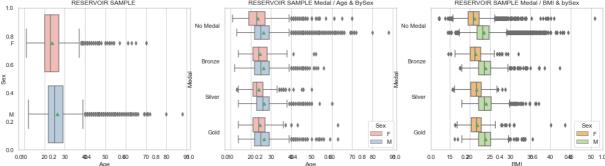
```
plt.figure(figsize=(5,5))
plt.title('STRATIFIED SMOTE Age & bySex')
plot1= sns.boxplot(data=stratified_SMOTE.sort_values(by="Age",ascending=True), x="Ag
plot1.figure.savefig("Grafico1_age_sex_plot.png")
```



(*) Los resultados obtenidos con el método Stratified SMOTE Sampling no son comparables con el resto de muestras, al haber tenido que reducir los registros que contenian valores "NaN"

6.6 Reservoir Sample Boxplot

```
In [981...
           fig, axes = plt.subplots(1, 3, figsize=(20, 5), sharey=True)
           ax4 = fig.add_subplot(1, 3, 1)
           sns.set(style="whitegrid")
           plt.title(f'RESERVOIR SAMPLE ')
           ax4= sns.boxplot(data= reservoir_sample.sort_values(by="Age"), x="Age", y="Sex",orie
           ax5 = fig.add_subplot(1, 3, 2)
           sns.set(style="whitegrid")
           plt.title(f'RESERVOIR SAMPLE Medal / Age & BySex')
           ax5= sns.boxplot(data= reservoir sample.sort values(by="Age"), x="Age", y="Medal", or
           ax6 = fig.add_subplot(1, 3, 3)
           sns.set(style="whitegrid")
           plt.title(f'RESERVOIR SAMPLE Medal / BMI & bySex')
           ax6= sns.boxplot(data= reservoir_sample.sort_values(by="BMI"), x="BMI", y="Medal",or
                    RESERVOIR SAMPLE
                                               RESERVOIR SAMPLE Medal / Age & BySex
                                                                               RESERVOIR SAMPLE Medal / BMI & bySex
```



Este método de muestreo es uno de los que mejor ajusta la edad média del colectivo de atletas femeninas clasificadas por tipos de medallas